
3.2 面向跨工况泛化的结构自适应去噪表征学习方法

3.2.1 方法原理

在运行条件发生变化时，尽管系统的物理结构与内在故障机理保持不变，但转速、载荷及噪声水平的改变会引起被测信号统计特性及其时频结构的显著变化。对于端到端诊断范式下的深度神经网络而言，其跨工况泛化能力主要取决于特征提取阶段所学习表征的鲁棒性与判别性，以及网络结构对不同信号复杂度的自适应调节能力。基于上述需求，自编码器（Auto-Encoder, AE）及其去噪与堆叠扩展模型为构建稳定特征表征提供了一种有效途径。

AE 由编码映射与解码映射两个阶段组成，用于在无监督条件下学习输入数据的低维潜在表示。设原始输入样本为 $X \in \mathbb{R}^d$ ，编码器通过非线性映射 $H = f_\theta(X)$ 将输入映射至特征空间，其中 $H \in \mathbb{R}^p$ 表示隐层特征， $f_\theta(\cdot)$ 为编码映射函数， θ 为网络参数。随后，解码器通过映射 $\hat{X} = g_\theta(H)$ 对特征进行重构，得到对输入的近似重构结果，其中 $g_\theta(\cdot)$ 表示解码映射函数。AE 通过最小化 X 与 $\hat{X}$ 之间的重构误差，在一定程度上提取输入数据中的结构特征。然而，当输入信号受到噪声污染时，AE 倾向于同时学习有效特征与噪声成分，其重构结果对输入扰动较为敏感，导致重构性能显著下降。

为增强特征学习过程对输入扰动的鲁棒性，去噪自编码器（Denoising Auto-Encoder, DAE）在训练阶段对原始输入样本 X 施加随机扰动，生成带噪输入 $\tilde{X} \sim q_D(\tilde{X}|X)$ ，其中 $q_D(\cdot)$ 示噪声扰动过程。编码器以 $\tilde{X}$ 作为输入，通过非线性映射获得隐含特征表示 $H = f_\theta(\tilde{X})$ ，随后，解码器根据隐含特征对输入进行重构，得到 $\hat{X} = g_\theta(H)$ 。在训练过程中，DAE 以重构原始信号 X 为学习目标，最小化 X 与 $\hat{X}$ 之间的重构误差，引导网络在特征学习过程中忽略随机扰动所引入的噪声成分。由于编码器在带噪输入条件下仍需恢复原始信号结构，DAE 被迫学习对输入扰动不敏感的稳定特征表示，从而在一定程度上实现噪声抑制与特征鲁棒性的提升。

在此基础上，堆叠去噪自编码器（Stacked Denoising Auto-Encoder, SDAE）将多个 DAE 逐层堆叠，实现对输入信号的逐级提取，其结构示意图如图 3-1 所示。对于第 1 个 DAE，原始输入样本 X 在训练阶段首先施加随机扰动，并通过编码映射获得特征表示 H_1 ，随后由对应的解码器对输入进行重构，得到重构结果 $\hat{X}$ 。对于第 i 个 DAE ($i \geq 2$)，其输入为上一层编码器的输出 H_{i-1} 。该层通过编码映射 $H_i = f_\theta(H_{i-1})$ 获得第 i 层的特征表示，并通过对应的解码器对 H_{i-1} 重构，得到 $\hat{H}_{i-1}$ 。其中， $H_0 = X$ ， H_{i-1} 表示第 i 层学习到的特征表示， θ_i 为该层的网络参数。通过逐层执行上述过程，SDAE 能够在不依赖标签信息的情况下，逐级提取由低层到高层的特征表示。

在训练策略上，SDAE 采用逐层无监督预训练与整体监督微调相结合的方式。其中，在预训练阶段对堆叠结构中的每一层 DAE 进行独立优化，各层网络参数的学习目标均以恢复输入数据的内在结构为核心。通常采用均方误差（Mean Squared Error, MSE）来度量网络对输入结构的重构能力，其形式如下：




图 3-1 堆叠去噪自编码器的结构示意图

$$J_{\text{MSE}} = \frac{1}{2m} \sum_{i=1}^m \|x_i - \hat{x}_i\|_2^2 \quad (3-2)$$

式中 m 表示训练样本数量， x_i 与 $\hat{x}_i$ 分别表示第 i 个样本的原始输入与对应的重构结果。

进一步地，为抑制深层网络在无监督训练过程中的过拟合倾向，引入权值惩罚项 J_w 以约束网络连接权值的幅值；同时，为提升特征学习的紧凑性与泛化潜力，引入稀疏约束项 J_s 对隐层神经元的激活分布施加约束，以抑制无效特征的激活与冗余表征的产生。由此构造 SDAE 在无监督预训练阶段的综合损失函数：

$$J_{\text{SDAE}} = J_{\text{MSE}} + \lambda_1 J_w + \lambda_2 J_s \quad (3-3)$$

式中 $J_w = \frac{1}{2} \sum_{l=1}^{k-1} \sum_{j=1}^{n_l} \sum_{i=1}^{n_{l-1}} (w_{ij}^l)^2$ ， k 表示网络层数， n_l 为第 l 层神经元数量， w_{ij}^l 为第 $l-1$ 层至第 l 层的连接权值； $J_s = \sum_{j=1}^{n_l} \left(\rho \log \frac{\rho}{\rho_j} + (1-\rho) \log \frac{1-\rho}{1-\rho_j} \right)$ ， ρ 为预设稀疏水平， ρ_j 表示第 j 个隐层神经元在训练样本上的平均激活程度。通过上述权值正则化与稀疏约束的引入，预训练阶段能够在一定程度上提升对输入扰动与噪声变化的稳定性，并降低冗余特征对后续跨工况学习过程的干扰。

在无监督预训练过程中，SDAE 采用逐层贪婪训练机制，即首先训练仅包含单一隐含层的网络，在该层参数收敛后，将其编码输出作为下一层自编码器的输入，依次完成多层网络的逐层训练。通过这种方式，各层编码器参数能够在局部重构准则下获得合

理初始化，为后续的整体监督微调提供稳定的参数基础。在完成逐层预训练后，将各层编码器串联形成深层网络，并在网络末端引入 Softmax 分类器以实现故障诊断功能。其输出可表示为：

$$p(y_i = j | H_n(x_i); \theta) = \frac{\exp(\theta_j^T H_n(x_i))}{\sum_{l=1}^C \exp(\theta_l^T H_n(x_i))}, \quad j = 1, 2, \dots, C \quad (3-4)$$

式中 $H_n(x_i)$ 表示样本 x_i 经 SDAE 编码后得到的高层特征表示， C 为故障类别数量， θ_j 为对应类别的分类权重参数， $p(y_i = j | H_n(x_i); \theta)$ 表示样本 x_i 被判定为第 j 类的概率。

在监督微调阶段，利用带标签样本通过反向传播算法对网络整体参数进行联合优化，以最小化模型输出与真实标签之间的差异。传统 SDAE 在该阶段通常采用如下误差代价函数：

$$J(\omega, b) = \frac{1}{2m} \sum_{i=1}^m \left| h_{\omega, b}(x^{(i)}) - y^{(i)} \right|^2 \quad (3-5)$$

式中 ω 与 b 为网络权重与偏置参数， $h_{\omega, b}(x^{(i)})$ 和 $y^{(i)}$ 表示第 i 个样本的预测值与真实值。该形式在分类任务中通过对输出概率与标签编码之间的差异进行度量实现监督学习，并便于与后续引入的判别约束项进行统一建模。

从特征分布角度看，上述微调目标函数主要关注输出误差的最小化，未对特征空间中样本分布结构施加显式约束。在运行条件发生变化时，源工况与目标工况下样本在特征空间中的分布可能出现明显偏移，同类样本与异类样本在高层特征空间中易发生混叠，从而使判别边界对工况与噪声扰动表现出较高敏感性。因而，仅依赖传统输出误差最小化的微调策略，难以从机制上有效缓解运行条件变化所引起的特征分布漂移问题。基于上述分析，为引导网络参数优化过程朝着更具判别性的方向发展，在监督微调阶段引入样本同类聚合与异类分离的判别约束，构建新的误差代价函数，如下所示：

$$J_{\text{new}}(\omega, b) = J(\omega, b) + \mu_1 J_1(\omega, b) - \mu_2 J_2(\omega, b) \quad (3-6)$$

式中 $J_1(\omega, b) = \frac{1}{2} \sum_{j=1}^C \sum_{i=1}^{m_j} \left\| h_{\omega, b}(x^{(ij)}) - M^{(j)} \right\|^2$ 用于衡量同类样本之间的误差， m_j 为第 j 类样本的数量， $M^{(j)} = \frac{1}{m_j} \sum_{i=1}^{m_j} h_{\omega, b}(x^{(ij)})$ 为第 j 类样本的均值。 $J_2(\omega, b) = \frac{1}{2} \sum_{i=1}^C \sum_{j=i+1}^C \left\| M^{(i)} - M^{(j)} \right\|^2$ 用于衡量不同类型样本之间的误差， $M^{(i)}$ 和 $M^{(j)}$ 分别表示第 i 类样本和第 j 类样本的均值， μ_1 和 μ_2 为权重系数。

在微调过程中，通过引导同类样本在特征空间中向各自类别中心聚集，使同类型样本之间的误差项 $J_1(\omega, b)$ 不断减小，从而抑制运行条件变化引起的类内分布扩散；同时，通过拉大不同类别样本中心在特征空间中的距离，使不同类型样本之间的误差项 $J_2(\omega, b)$ 不断增大，以增强高层特征表征的类间分离性。二者通过对特征空间中类内紧凑性与类间分离性的联合约束，有效缓解运行条件变化导致的判别结构退化问题，使




图 3-2 基于误差收敛行为的结构自适应搜索机制

模型在不同工况与噪声条件下保持更加一致的诊断响应。

基于上述综合误差函数 $J_{new}(\omega, b)$ ，网络优化过程在参数空间中被引导至兼顾类内紧凑性与类间分离性的判别方向。然而，该判别约束的有效性并非仅由误差函数本身决定，而在很大程度上受限于网络结构所提供的表示容量。当运行条件与噪声水平发生变化时，特征空间的复杂度及其分布形态亦随之改变，固定的网络深度与节点规模难以在不同工况下始终匹配合适的模型容量。因此，有必要进一步引入能够动态确定网络隐含层数与节点规模的结构自适应调节机制。为此，将 $J_{new}(\omega, b)$ 的收敛行为与网络结构选择过程相结合，构建一种基于 $J_{new}(\omega, b)$ 变化趋势的 SDAE 结构自适应调整策略，其整体流程如图 3-2 所示。

具体而言，在给定初始网络结构的条件下，首先执行逐层无监督预训练与固定结构下的监督微调，并在微调过程中同步监测综合误差函数 $J_{new}(\omega, b)$ 随训练迭代次数的变化趋势，以评估当前网络结构对输入特征复杂度的适配程度。若误差函数能够随迭代次数的增加快速下降并稳定逼近预设阈值，则认为当前网络结构已具备足够的表示能力，终止结构搜索过程并保留该网络模型作为最优结构；反之，若误差函数随迭代次数增加表现出明显振荡或难以稳定收敛的特征，则认为当前网络容量不足以有效刻画输入数据的判别特征。在此情况下，优先在保持网络深度不变的前提下，逐步增加隐




图 3-3 面向跨工况诊断的结构自适应 SDAE 整体框架

含层节点数以提升模型表示容量；若在节点规模调整后，误差函数仍无法稳定下降并逼近阈值，则进一步增加网络隐含层数，以增强网络对复杂特征结构的分层建模能力。上述过程以误差收敛判据为导向迭代执行，直至获得满足判别性能要求的网络结构。

基于上述判别约束微调机制与结构自适应调节策略，在 SDAE 的基础上构建了一种改进堆叠去噪自编码器（Improved Stacked Denoising Auto-Encoder, ISDAE），由此形成面向跨工况故障诊断的 ISDAE 整体建模流程，其方法框架如图 3-3所示。该框架以多源振动信号为输入，依次经过数据预处理、逐层无监督预训练、基于综合误差函数 J_{new} 的监督微调以及误差判据驱动的结构自适应调整，实现网络结构与参数的联合优化。最终，保留在当前运行条件下具有最优判别性能的 SDAE 结构，并将其用于后续跨工况滚动轴承故障诊断任务。

3.2.2 实验设计与结果分析

为验证所提出的 ISDAE 算法在运行条件变化下的故障诊断性能，基于如图 3-4所示的 VALENIAN-PT650 系列旋转设备平台，开展多转速、多载荷及多噪声水平下的滚动轴承故障诊断实验。该平台主要由三相鼠笼式异步电机、传动联轴器、被测滚动轴承、磁粉制动器以及多通道振动传感器构成。其中，三相鼠笼式异步电机作为系统动力源，通过传动联轴器与轴承转轴相连，用于驱动轴承系统在不同转速条件下稳定运行；磁粉制动器安装于轴系末端，用于对系统施加可调机械负载，从而在保持系统结构与故障机理不变的前提下，模拟不同工况下轴承的受力状态。

实验平台在轴承座的正交方向分别布置振动传感器，以 6 kHz 的采样频率同步采集不同空间方向上的振动响应信息，并在每一种转速与载荷组合条件下连续采样 100 秒，以保证采集数据具有统计代表性。选取 PH206 型滚动轴承作为故障诊断的研究对象，采用人工切削的方法在轴承关键部位引入局部损伤，以构造滚动轴承在工程实践中常见的多种失效模式。定义六种在物理机理上具有明显差异的轴承状态，并统一采用符号 S1–S6 进行标识。其中 S1 表示正常运行状态；S2–S5 为单一故障类型，包括内圈故障、外圈故障、保持架故障以及滚动体故障；S6 为同时包含内圈与外圈故障的